

Тема: Знакомство с инструментами сбора и подготовки данных.

Цель: Изучить возможности программного обеспечения Orange Data Mining. Освоить основные методики загрузки данных из внешних источников, очистки и подготовки их для дальнейшего анализа. Научиться создавать базовые визуализации для анализа качества данных.

Выполнение работы

Подготовить рабочее пространство – установить и настроить дистрибутив программного обеспечения Orange 3.39.0.

2. По согласованию с преподавателем выбрать источник данных и определиться с набором для дальнейшего анализа.

3. Выполнить загрузку исходных данных и произвести их первичный анализ на полноту и целостность.

4. Выявить и визуализировать проблемы качества полученных данных.

5. Выполнить очистку данных с обоснованием выбранных методов.

6. Применить методы преобразования и нормализации данных.

7. Провести исследовательский анализ и сформировать информативные визуализации для анализа данных.

8. Сохранить результаты проделанной работы в различных форматах для подготовки аналитического отчета.

9. Подготовить аналитический отчет по результатам работы.

Задание 1.




Рисунок 1 – Главное окно «Orange Data Mining»

Задание 2. Исходные данные.

index	Order ID	Date	Status	Fulfilment	Sales Channel	ship-service-level	Style	SKU	Category	Size	ASIN	Courier Status	Qty	currency	Amount	ship-city	ship-state	ship-postal-code	ship-country	promotion-ids	B2B	fulfillment-channel
1	0,405-8078784-5731545	04-30-22	Cancelled	Merchant	Amazon.in	Standard	SET389	SET389-KR-NP-S	Set,S	B09KXVBD7Z	0,INR,647.62	MUMBAI,MAHARASHTRA	400081.0	IN,,False	Easy Ship							
2	1,171-9198151-1101146	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	JNE3781	JNE3781-KR-XXXL	kurta,3XL	B09K3WFS32	Shipped,1	INR,406.0	BENGALURU,KARNATAKA	560085.0	IN,,False	Easy Ship					
3	2,404-0687676-7273146	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3371	JNE3371-KR-XL	kurta,XL	B07WV4JV4D	Shipped,1	INR,329.0	NAVI MUMBAI,MAHARASHTRA	410210.0	IN,IN Core Free Shipping 2015/04/08							
4	3,403-9615377-8133951	04-30-22	Cancelled	Merchant	Amazon.in	Standard	J0341	J0341-DR-L	Western Dress,L	B099NRC7B	0,INR,753.33	PUDUCHERRY,PUDUCHERRY	605008.0	IN,,False	Easy Ship							
5	4,407-1069790-7240320	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3671	JNE3671-TU-XXXL	Top,3XL	B098714BZP	Shipped,1	INR,574.0	CHENNAI,TAMIL NADU	600073.0	IN,,False							
6	5,404-1490984-4578765	04-30-22	Shipped	Amazon	Amazon.in	Expedited	SET264	SET264-KR-NP-XL	Set,XL	B08YX7XDSG	Shipped,1	INR,824.0	GHAZIABAD,UTTAR PRADESH	201102.0	IN,IN Core Free Shipping 2015/04/08							
7	6,408-5748499-6859555	04-30-22	Shipped	Amazon	Amazon.in	Expedited	J0095	J0095-SET-L	Set,L	B08CMHNVBN	Shipped,1	INR,653.0	CHANDIGARH,CHANDIGARH	160036.0	IN,IN Core Free Shipping 2015/04/08	23-48-5						
8	7,406-7807733-3785945	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	JNE3405	JNE3405-KR-S	kurta,S	B081WX4G4Q	Shipped,1	INR,399.0	HYDERABAD,TELANGANA	500032.0	IN,,False	Easy Ship					
9	8,407-5443024-5233168	04-30-22	Cancelled	Amazon	Amazon.in	Expedited	SET200	SET200-KR-NP-A	XXXL	Set,3XL	B08191ZZXN	Cancelled,0,,	HYDERABAD,TELANGANA	500008.0	IN,IN Core Free Shipping 2015/04/08	23-48-5						
10	9,402-4393761-0311520	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3461	JNE3461-KR-XXL	kurta,XXL	B08B3XF5MH	Shipped,1	INR,363.0	Chennai,TAMIL NADU	600041.0	IN,,False							
11	10,407-5633625-6970741	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3160	JNE3160-KR-G-S	kurta,S	B07K3YQLF1	Shipped,1	INR,685.0	CHENNAI,TAMIL NADU	600073.0	IN,,False							
12	11,171-4638481-6326716	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3500	JNE3500-KR-XS	kurta,XS	B098117DJ3	Shipped,1	INR,364.0	NOIDA,UTTAR PRADESH	201303.0	IN,,False							
13	12,405-5513694-8146768	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	JNE3405	JNE3405-KR-XS	kurta,XS	B081XCMYXJ	Shipped,1	INR,399.0	Amravati,MAHARASHTRA	444606.0	IN,,False	Easy Ship					
14	13,408-795685-3083534	04-30-22	Shipped	Amazon	Amazon.in	Expedited	SET182	SET182-KR-DH-XS	Set,XS	B08SHS947T	Shipped,1	INR,657.0	MUMBAI,MAHARASHTRA	400053.0	IN,,False							
15	14,408-1298370-1920302	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	J0351	J0351-SET-L	Set,L	B09CSSQY4F	Shipped,1	INR,771.0	MUMBAI,MAHARASHTRA	400053.0	IN,,False	Easy Ship					
16	15,403-4965581-9520319	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	PJNE3368	PJNE3368-KR-6XL	kurta,6XL	B09PY995VJ	Shipped,1	INR,544.0	GUNTAKAL,ANDHRA PRADESH	515801.0	IN,,False	Easy Ship					
17	16,406-9379318-6555504	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3721	JNE3721-KR-XXL	kurta,XXL	B099CF65D	Shipped,1	INR,329.0	JAIPUR,RAJASTHAN	302020.0	IN,IN Core Free Shipping 2015/04/08	23-48-5						
18	17,405-9013803-8009918	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3405	JNE3405-KR-XL	kurta,XL	B081WT6GG7	Shipped,1	INR,399.0	NEW DELHI,DELHI	110074.0	IN,,False							
19	18,402-4030358-5835511	04-30-22	Shipped	Delivered to Buyer	Merchant	Amazon.in	Standard	JNE3697	JNE3697-KR-XXL	kurta,XXL	B098133PV5	Shipped,1	INR,458.0	Gurgaon,HARYANA	122004.0	IN,,False	Easy Ship					
20	19,405-5957858-1051546	04-30-22	Shipped	Amazon	Amazon.in	Expedited	SET254	SET254-KR-NP-XS	Set,XS	B0983DDPL6	Shipped,1	INR,886.0	BENGALURU,KARNATAKA	560017.0	IN,,False							
21	20,405-0607769-0716360	04-30-22	Shipped	Amazon	Amazon.in	Expedited	JNE3795	JNE3795-KR-XXXL	kurta,3XL	B09HMXJVFS	Shipped,1	INR,517.0	TIRUCHIRAPPALLI,TAMIL NADU	620018.0	IN,IN Core Free Shipping 2015/04/08	23-48-5						
22	21,404-8494550-5860325	04-30-22	Shipped	Amazon	Amazon.in	Expedited	SET345	SET345-KR-NP-M	Set,M	B09KXV48N8	Shipped,1	INR,666.0	BENGALURU,KARNATAKA	560040.0	IN,IN Core Free Shipping 2015/04/08	23-48-5						

Рисунок 2 – Набор табличных данных

Задание 3. Загрузка и первичный анализ данных




Рисунок 3 – Загрузка данных




Рисунок 4 – Workflow

Задание 4. Обнаружение и анализ проблем качества данных




Рисунок 5 – Data Info

С помощью виджета Select Rows были обнаружены записи с пропусками в столбцах.

The image shows two side-by-side screenshots of data tables in Orange. The left table, titled 'Data Table (2) - Orange', has columns: currency, Amount, ship-state, ship-postal-code, ship-country, and 828. The right table, titled 'Data Table (4) - Orange', has columns: index, Date, Status, Fulfilment, Sales Channel, and ship-service-le. Both tables show data with missing values (NaN) in the 'ship-country' and 'index' columns respectively.

currency	Amount	ship-state	ship-postal-code	ship-country	828
NR	888.00	ANDHRA PRAD...	533126.0	IN	False
NR	371.00	TAMIL NADU	600042.0	IN	False
NR	771.00	KERALA	695541.0	IN	False
NR	0.00	JAMMU & KAS...	194101.0	IN	False
NR	690.00	MAHARASHTRA	411027.0	IN	False
NR	885.00	ANDHRA PRAD...	531001.0	IN	False
NR	771.00	MAHARASHTRA	411033.0	IN	False
NR	1186.00	KERALA	683515.0	IN	False
NR	721.00	MAHARASHTRA	400072.0	IN	False
NR	771.00	KERALA	688013.0	IN	False
NR	1229.00	BIHAR	800026.0	IN	False
NR	771.00	UTTAR PRADESH	201301.0	IN	False
NR	599.00	KARNATAKA	572102.0	IN	False
NR	759.00	RAJASTHAN	325221.0	IN	False
NR	1132.00	TELANGANA	502270.0	IN	False
NR	487.00	CHHATTISGARH	490011.0	IN	False
NR	967.00	KARNATAKA	560028.0	IN	False
NR	1556.00	KARNATAKA	560028.0	IN	False
NR	355.00	RJ	342009.0	IN	False
NR	771.00	TAMIL NADU	600062.0	IN	False
NR	885.00	MADHYA PRAD...	462039.0	IN	False
NR	788.00	BIHAR	854301.0	IN	False
NR	582.00	MAHARASHTRA	400006.0	IN	False
NR	383.00	MAHARASHTRA	411036.0	IN	False
NR	999.00	TELANGANA	509001.0	IN	False
NR	1072.00	TELANGANA	500026.0	IN	False
NR	771.00	TELANGANA	500017.0	IN	False
NR	377.00	KERALA	688535.0	IN	False
NR	545.00	ASSAM	781001.0	IN	False
NR	736.00	KARNATAKA	560049.0	IN	False
NR	545.00	JHARKHAND	834001.0	IN	False
NR	574.00	JHARKHAND	834001.0	IN	False
NR	857.00	KARNATAKA	560102.0	IN	False

index	Date	Status	Fulfilment	Sales Channel	ship-service-le
13253	13252	04-22-22	Cancelled	Merchant	Amazon.in
16788	16787	04-20-22	Shipped - Deliv...	Merchant	Amazon.in
22931	22930	04-16-22	Shipped - Retur...	Merchant	Amazon.in
30380	30379	04-12-22	Shipped - Deliv...	Merchant	Amazon.in
37964	37963	04-08-22	Cancelled	Merchant	Amazon.in
37965	37964	04-08-22	Cancelled	Merchant	Amazon.in
58609	60986	05-22-22	Shipped - Deliv...	Merchant	Amazon.in
66662	73675	05-11-22	Shipped - Deliv...	Merchant	Amazon.in
71021	80011	05-07-22	Shipped - Retur...	Merchant	Amazon.in
71344	80455	05-06-22	Shipped - Deliv...	Merchant	Amazon.in
74176	84008	05-04-22	Shipped - Retur...	Merchant	Amazon.in
89863	104201	06-18-22	Shipped - Deliv...	Merchant	Amazon.in
107673	126620	06-02-22	Shipped - Deliv...	Merchant	Amazon.in
1	0	04-30-22	Cancelled	Merchant	Amazon.in
2	1	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
4	3	04-30-22	Cancelled	Merchant	Amazon.in
8	7	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
13	12	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
15	14	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
16	15	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
19	18	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
24	23	04-30-22	Cancelled	Merchant	Amazon.in
26	25	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
27	26	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
30	29	04-30-22	Cancelled	Merchant	Amazon.in
33	32	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
34	33	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
36	35	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
43	42	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
50	49	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
61	60	04-30-22	Shipped - Deliv...	Merchant	Amazon.in
71	70	04-30-22	Shipped - Deliv...	Merchant	Amazon.in

Рисунок 6 – Записи без пропусков (слева) и с пропусками (справа)




Рисунок 8 – Distributions

На рисунке 8 видно, что столбец Sales Channel содержит одинаковые значения. Этот столбец можно исключить.

На рисунке 9 видно, что после обработки виджетов Unique количество строк таблицы не изменилось, что означает что дубликатов нет.




Рисунок 9 – Unique и проверка дубликатов




Рисунок 10 – Выбор записей с отрицательными числовыми значениями

В моем датасете все даты хранятся в формате ММ-DD-YY.

Задание 5. Очистка данных

Для преобразования даты в корректный формат согласно стандарту ISO-8601 был использован виджет Formula.




Рисунок 11 – Исправление даты

Для заполнения данных с пустыми значениями был использован виджет Impute. Данные столбца Ship-country были заполнены значением IN, так как все остальные строки этим значением.





Рисунок 12 – Impute



Задание 6. Создание и преобразование признаков

Дата была разбита на отдельные столбцы Year, Month, Day. Столбец с названиями городов был отформатирован чтобы города отображались с большой буквы.






Рисунок 13 – Исправление других столбцов

Задание 7. Нормализация и стандартизация данных

Использование Normalize



Задание 8. Исследовательский анализ и визуализация

IAD LR 1.ows* - Orange

File Edit View Widget Window Options Help

Filter...

Data

- File
- CSV File Import
- Datasets
- SQL Table
- Data Table
- Paint Data
- Data Info
- Rank
- Edit Domain
- Color
- Feature Statistics
- Save Data

Transform


- Data Sampler
- Select Columns
- Select Rows
- Transpose

Save Data

Save data to an output file.

[more...](#)

1 # T [] || ?



Выводы

В данной лабораторной работе я изучил возможности программного обеспечения Orange Data Mining. Освоил основные методики загрузки данных из внешних источников, очистки и подготовки их для дальнейшего анализа. Научился создавать базовые визуализации для анализа качества данных.