


Тема: Методы классификации и кластеризации данных.

Цель: Научиться использовать программное обеспечение Orange Data Mining для реализации задач классификации и кластеризации данных. Рассмотреть основные возможности разведочного анализа данных (EDA). Научиться применять методы классификации и кластеризации путем настройки параметров для корректной интерпретации результатов анализа.

Выполнение работы

1. По согласованию с преподавателем подготовить набор данных для анализа.
2. Выполнить разведочный анализ данных (EDA).
3. Применить различные алгоритмы классификации к данным.
4. Провести оценку качества классификации и сравнить полученные результаты различными методами.
5. Применить различные методы кластеризации для группировки данных.
6. Провести оценку качества полученных кластеров разными методами.
7. Реализовать визуализацию результатов классификации и кластеризации.
8. Сохранить результаты проделанной работы в различных форматах для подготовки аналитического отчета.
9. Подготовить аналитический отчет по результатам работы.

Задание 1. Подготовка данных для анализа



Data Info - Orange

Data table properties

Name: kickstarter

Size: ~1163 rows, 20 columns

Features: 2 categorical, 13 numeric

Targets: categorical outcome with 2 classes

Metas: 1 categorical, 3 text

Missing data: none

Additional attributes

| 1163

Select Columns - Orange

Ignored (1)

Filter

S URL

Features (15)

Filter

C Type
C Has FB
N Backed Projects
N Previous Projects
N Creator Desc Len
N Title Len
N Goal
N Duration
N Pledge Levels
N Min Pledge Tiers
N Max Pledge Tiers
N Proj Desc Len
N Images

Target (1)


C Funded


Metas (3)

S Title
S Year
C Month

Reset
☐ Ignore new variables by default
☒ Send Automatically

1163 | - 1163 | 15





Data Sampler - Orange

Sampling Type

☒ Fixed proportion of data:

[Slider] 80 %

☐ Fixed sample size

Instances:

☐ Sample with replacement

☐ Cross validation

Number of subsets:

Unused subset:


☐ Bootstrap

Options


☒ Replicable (deterministic) sampling



☐ Stratify sample (when possible)

1163 815 | 348



Задание 2. Разведочный анализ данных







Задание 3. Классификация данных

IAD LR 2.ows - Orange

File Edit View Widget Window Options Help

Random Forest - Orange

Name: Random Forest

Basic Properties

Number of trees: 10

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution

Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 5

Tree - Orange

Name: tree

Parameters

☒ Induce binary tree

☒ Min. number of instances in leaves: 2

☒ Do not split subsets smaller than: 10

☒ Limit the maximal tree depth to: 5

Classification

☒ Stop when majority reaches [%]: 95

☒ Apply Automatically

SVM - Orange

Name: SVM

SVM Type

☒ SVM

Cost (C): 1.00

Regression loss epsilon (epsilon): 0.10

☐ v-SVM

Regression cost (C): 1.00

Complexity bound (nu): 0.50

Kernel

☐ Linear

Kernel: $\exp(-\gamma |x \cdot y|^2)$

☐ Polynomial

g: auto

☒ RBF

☐ Sigmoid

Optimization Parameters

Numerical tolerance: 0.0010

☒ Iteration limit: 100

☒ Apply Automatically

KNN - Orange

Name: kNN

Neighbors

Number of neighbors: 12

Metric: Euclidean

Weight: Uniform

☒ Apply Automatically

Logistic Regression - Orange

Name: Logistic Regression

Regularization type: Ridge (L2)

Strength: Weak

C=10

☐ Balance class distribution

☒ Apply Automatically

Задание 4. Оценка качества классификации

Test and Score - Orange

☒ Cross validation
 Number of folds: 3
☒ Stratified

☐ Cross validation by feature
 Month

☐ Random sampling
 Repeat train/test: 10
 Training set size: 66 %
☒ Stratified

☐ Leave one out
☐ Test on train data
☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Prec	Recall	MCC
Random Forest	0.905	0.828	0.827	0.827	0.828	0.644
Logistic Regression	0.906	0.843	0.843	0.843	0.843	0.676
kNN	0.754	0.691	0.681	0.688	0.691	0.347
SVM	0.863	0.793	0.793	0.794	0.793	0.575

Compare models by: Area under ROC cu ☐ Negligible diff.: 0.1

	Random ...	Logistic R...	kNN	SVM
Random Forest		0.402	0.985	0.881
Logistic Regression	0.598		0.991	0.919
kNN	0.015	0.009		0.002
SVM	0.119	0.081	0.998	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

1000 | 1000 | 1000 | 1000 | 1000 | 4x1000

Задание 5. Кластеризация данных

Tree (1) - Orange

Name
 Tree (1)

Parameters

☒ Induce binary tree

☒ Min. number of instances in leaves: 2

☒ Do not split subsets smaller than: 5

☒ Limit the maximal tree depth to: 100


Classification

☒ Stop when majority reaches [%]: 95

☒ Apply Automatically

1000 | - | 1000

Задание 6. Оценка качества классификации



Задание 8. Анализ и интерпретация результатов

Выводы

В данной лабораторной работе я научился использовать программное обеспечение Orange Data Mining для реализации задач классификации и кластеризации данных. Рассмотрел основные возможности разведочного анализа данных (EDA). Научился применять методы классификации и кластеризации путем настройки параметров для корректной интерпретации результатов анализа.