

ЛАБОРАТОРНАЯ РАБОТА №1

Тема: Знакомство с инструментами сбора и подготовки данных.

Цель: Изучить возможности программного обеспечения Orange Data Mining. Освоить основные методики загрузки данных из внешних источников, очистки и подготовки их для дальнейшего анализа. Научиться создавать базовые визуализации для анализа качества данных.

Задания:

1. Подготовить рабочее пространство – установить и настроить дистрибутив программного обеспечения **Orange 3.39.0**.
2. По согласованию с преподавателем выбрать источник данных и определиться с набором для дальнейшего анализа.
3. Выполнить загрузку исходных данных и произвести их первичный анализ на полноту и целостность.
4. Выявить и визуализировать проблемы качества полученных данных.
5. Выполнить очистку данных с обоснованием выбранных методов.
6. Применить методы преобразования и нормализации данных.
7. Провести исследовательский анализ и сформировать информативные визуализации для анализа данных.
8. Сохранить результаты проделанной работы в различных форматах для подготовки аналитического отчета.
9. Подготовить аналитический отчет по результатам работы.

В отчет обязательно должно входить:

- описание исходного набора данных (источник, оценка качества исходных данных с указанием обнаруженных проблем, общая структура исходного набора);
- перечисление основных выполненных шагов с описанием используемых компонент Orange (их параметры);
- перечисление примененных методов с пояснением выбора конкретных методов очистки и преобразования;
- характеристика полученных итоговых данных (описание структуры, особенности и выделение наиболее показательных информативных признаков);
- рекомендации для дальнейшего анализа с предложениями направлений для углубленного анализа.

Отчет должен сопровождаться экспортированными визуализациями из Orange и скринами построенных схем обработки.

Методические рекомендации по выполнению практического задания

Задание 1.

Загрузите дистрибутив программного обеспечения с официального сайта Orange Data Mining: <https://orangedatamining.com/download/>

Следуя инструкциям разработчиков, установите, настройте и запустите среду визуального программирования **Orange 3.39.0**.

Задание 2.

Исходные данные

Для выполнения работы рекомендуется использовать набор табличных данных в формате CSV, содержащий смешанные типы данных (числовые, категориальные, текстовые, временные). В наборе данных должно быть: не менее 500 записей, не менее 6 столбцов, различные типы данных.

Возможные источники данных:

- Kaggle Datasets
- UCI Machine Learning Repository
- Google Dataset Search
- Data.gov

Рекомендуется использовать датасеты из ресурса **Kaggle**: <https://www.kaggle.com/datasets>

Рекомендуемые наборы данных:


"Online Sales Dataset" - данные интернет-магазинов

"E-commerce Data" - продажи электроники

"Retail Sales Dataset" - розничные продажи

"Customer Purchase Data" - данные о покупках

В строке поиска введите "online sales", "ecommerce" или "retail dataset". В списке результатов поиска выберите и переходите в понравившийся датасет. На странице набора данных ниже его описание можно найти сам датасет с кнопкой "скачать".



Для справки! в правом верхнем углу экрана есть секции code/download, в них вы сможете посмотреть примеры кода на **Python** для скачивания и автоматической загрузки данных.

Задание 3. Загрузка и первичный анализ данных

Сначала загрузите CSV-файл в Orange, используя виджет File. Убедитесь, что данные корректно импортировались. Проверьте правильность определения типов данных.

Подключите виджет Data Info и проанализируйте:

- Общее количество записей и признаков
- Автоматически определенные типы данных
- Количество уникальных значений в каждом столбце
- Процент пропущенных значений по столбцам

Для просмотра данных используйте виджет **Data Table** для просмотра первых 50-100 записей. Изучите структуру и содержимое каждого столбца. Обратите внимание на потенциальные проблемы.

В результате должно получиться:

- Скриншот workflow с подключенными виджетами
- Краткое описание структуры загруженных данных

Задание 4. Обнаружение и анализ проблем качества данных

Проведите анализ пропущенных значений. Для этого используйте **Data Info** для определения столбцов с пропусками. Примените **Data Table** с фильтрацией для просмотра записей с пропусками и оцените закономерности в распределении пропущенных значений.

Далее проведите поиск аномальных значений. Для числовых столбцов: используйте **Distributions** и **Box Plot**. Выявите потенциальные выбросы и нетипичные значения. Для категориальных данных проанализируйте распределение категорий.

Для обнаружения дублирующихся записей используйте **Data Table** с сортировкой по ключевым полям. (При необходимости примените **Unique** для анализа уникальных значений)

Проведите проверку логической целостности. Для этого выявите противоречия между связанными столбцами. Проверьте корректность значений (отрицательные цены, некорректные даты и т.п.)

Результатом должно быть:

- Документированный список всех выявленных проблем с данными
- Скриншоты соответствующих визуализаций

Задание 5. Очистка данных

Обработайте пропущенные значения, выбрав подходящую стратегию для каждого столбца: удаление записей/столбцов (если пропусков много), заполнение константой (например, "Unknown"), заполнение статистикой (среднее, медиана, мода) с использованием Impute, или заполнение на основе других данных.

Обработайте выбросы и аномальные значения. Определите критерии для выбросов (например, за пределами $1.5 \times IQR$). Используйте **Select Rows** для фильтрации данных. Выберите стратегию: удаление, замена, или сохранение с пометкой.

Устраните дубликаты, применив **Remove Duplicates** по всем полям или ключевым полям. Обоснуйте критерии определения дубликатов.

Исправьте некорректные значения, используя **Select Rows** для удаления логически некорректных записей. При необходимости примените **Feature Constructor** для исправления значений.

Результат:

- Workflow процесса очистки данных
- Сравнительная таблица количества записей до и после каждого этапа очистки
- Обоснование выбранных методов очистки

Задание 6. Создание и преобразование признаков

Создайте производные признаки, используя **Feature Constructor** для создания новых информативных признаков. Примеры: отношения между числовыми переменными, комбинированные категории.

Если есть временные данные (даты/время), извлеките компоненты: год, месяц, день недели, час. Создайте признаки временных интервалов или сезонности.

Преобразуйте категориальные данные, применив **Edit Domain** для корректировки типов данных. При необходимости используйте перекодирование категорий.

Если применимо, обработайте текстовые данные: очистка от лишних символов, извлечение длины текста или ключевых слов.

Результат:

- Описание всех созданных признаков с обоснованием их полезности

Задание 7. Нормализация и стандартизация данных

Выполните масштабирование числовых признаков, применив **Normalize** к числовым переменным. Используйте **Z-score** стандартизацию (нулевое среднее, единичная дисперсия) или **Min-Max** нормализацию (масштабирование в диапазон [0,1]). Обоснуйте выбор метода для каждого признака.

Проведите дискретизацию непрерывных переменных, используя **Discretize** для преобразования числовых данных в категориальные. Примените различные методы: равные интервалы, равные частоты, **k-means**.

Создайте бинарные индикаторы для важных условий, используя **Feature Constructor** с логическими выражениями.

Результат:

- Сравнение распределений данных до и после нормализации
- Обоснование выбранных методов преобразования

Задание 8. Исследовательский анализ и визуализация

Проведите одномерный анализ с помощью **Distributions** (гистограммы для числовых переменных) и **Bar Plot** (частоты для категориальных переменных). Опишите основные характеристики каждого признака.

Выполните двумерный анализ, используя Scatter Plot для связей между числовыми переменными, Box Plot для распределений по группам, Heat Map для матрицы корреляций.

Проведите многомерный анализ, используя цветовое кодирование и размер точек в scatter plot. Создайте группированные визуализации (например, по категориям).

Если применимо, проведите временной анализ с помощью Line Plot для трендов во времени. Проанализируйте сезонность и периодичность.

Результат:

- Набор информативных визуализаций с подписями
- Интерпретация основных закономерностей в данных

Задание 9. Сохранение результатов

Экпортируйте обработанные данные, сохранив очищенные данные в CSV формате с помощью **Save Data**. Создайте отдельные файлы для разных версий данных (сырые, очищенные, преобразованные).

Сохраните workflow в формате .ows. Убедитесь, что workflow можно воспроизвести.

Экпортируйте визуализации, сохранив ключевые графики в формате PNG/SVG. Создайте итоговый отчет с визуализациями.

Результат:

- Файлы с обработанными данными
- Сохраненный workflow
- Набор визуализаций

Задание 10. Анализ и выводы

Оцените качество исходных данных, составив сводку по проблемам качества данных. Оцените общее состояние исходного датасета.

Обоснуйте примененные методы, объяснив выбор конкретных методов очистки и преобразования. Обсудите альтернативные подходы и их плюсы/минусы.

Охарактеризуйте итоговые данные, описав структуру и особенности обработанных данных. Выделите наиболее информативные признаки.

Сформулируйте рекомендации для дальнейшего анализа, предложив направления для углубленного анализа. Определите потенциальные задачи машинного обучения для вашего набора

Результат:

- Аналитический отчет с выводами и рекомендациями

Полезные виджеты Orange для работы:

- **Data:** File, Save Data, Data Table, Data Info
- **Transform:** Select Rows, Feature Constructor, Discretize, Normalize, Impute
- **Visualize:** Distributions, Box Plot, Scatter Plot, Bar Plot, Heat Map, Line Plot
- **Unsupervised:** Remove Duplicates, Unique