

ЛАБОРАТОРНАЯ РАБОТА № 2

Тема: Методы классификации и кластеризации данных.

Цель: научиться использовать программное обеспечение Orange Data Mining для реализации задач классификации и кластеризации данных. Рассмотреть основные возможности разведочного анализа данных (EDA). Научиться применять методы классификации и кластеризации путем настройки параметров для корректной интерпретации результатов анализа.

Задания:

1. По согласованию с преподавателем подготовить набор данных для анализа.
2. Выполнить разведочный анализ данных (EDA).
3. Применить различные алгоритмы классификации к данным.
4. Провести оценку качества классификации и сравнить полученные результаты различными методами.
5. Применить различные методы кластеризации для группировки данных.
6. Провести оценку качества полученных кластеров разными методами.
7. Реализовать визуализацию результатов классификации и кластеризации.
8. Сохранить результаты проделанной работы в различных форматах для подготовки аналитического отчета.
9. Подготовить аналитический отчет по результатам работы.

В отчет обязательно должно входить:

- описание исходного набора данных;
- перечисление основных выполненных шагов с описанием используемых компонент Orange (их параметры);
- интерпретацию полученных результатов;
- ключевые выводы по используемым методам и полученным результатам.

Отчет должен сопровождаться экспортированными визуализациями из Orange и скринами построенных схем обработки.

Методические рекомендации по выполнению практического задания

Задание 1. Подготовка данных для анализа

Исходные данные

Для выполнения работы можно использовать уже подготовленный в лабораторной работе №1 набор данных или подготовить новый табличный набор данных в формате CSV.

Требования к набору данных:

- Не менее 300 записей для обеспечения репрезентативности
- Содержит как числовые, так и категориальные признаки
- Имеет целевую переменную для задачи классификации (категориальную)
- Подходит для решения задач без учителя (кластеризация)

Рекомендуемые источники:

- Результаты лабораторной работы №1
- Встроенные наборы данных Orange (iris, titanic, housing и др.)
- Kaggle, UCI ML Repository

Подготовка данных

Загрузите подготовленные данные в Orange через виджет File и используйте Data Info для анализа структуры данных. Убедитесь в наличии целевой переменной для классификации.

Используйте Select Columns для определения признаков (Features), целевой переменной (Target) и мета-информации (Meta). Убедитесь, что целевая переменная имеет тип Categorical.

Примените Distributions к целевой переменной для оценки распределения классов. При необходимости задокументируйте дисбаланс классов.

Используйте Data Sampler для разделения данных на обучающую выборку (70-80%) и тестовую выборку (20-30%). Выберите подходящую стратегию: случайная выборка или стратифицированная.

Результат:

- Workflow подготовки данных
- Характеристика целевой переменной и признаков

Задание 2. Разведочный анализ данных (EDA)

Проанализируйте связи признаков с целевой переменной. Для числовых признаков используйте Box Plot по классам целевой переменной, для категориальных признаков – Bar Plot с группировкой по целевой переменной. Создайте Scatter Plot с цветовым кодированием по целевой переменной.

Создайте Heat Map корреляций между числовыми признаками, выявите сильно коррелированные признаки и оцените связи признаков с целевой переменной.

Используйте Distributions для всех числовых признаков с разбивкой по классам, чтобы выявить признаки с наибольшей дискриминирующей способностью.

Если признаков много, используйте Linear Projection или t-SNE для оценки возможности разделения классов в пространстве признаков.

Результат:

- Комплексный анализ данных с визуализациями
- Выводы о наиболее информативных признаках

Задание 3. Классификация данных

Примените компонент Logistic Regression, подключив к обучающим данным.

Проанализируйте коэффициенты этой модели. Используйте Tree с настройкой параметров: максимальная глубина дерева и минимальное количество объектов в листе. Визуализируйте дерево с помощью Tree Viewer.

Примените kNN, экспериментируя с различными значениями k (3, 5, 10, 15). Выберите оптимальное значение. Используйте SVM, попробуйте разные ядра (linear, polynomial, RBF) и настройте параметры регуляризации.

Если доступен, примените Random Forest с настройкой количества деревьев.

Результат:

- Workflow с различными алгоритмами классификации
- Настроенные модели с обоснованием выбора параметров

Задание 4. Оценка качества классификации

Используйте Predictions для получения предсказаний на тестовой выборке и подключите Test & Score для вычисления метрик: Accuracy, Precision, Recall, F1-score, AUC (для бинарной классификации).

Используйте Confusion Matrix для анализа ошибок классификации. Проанализируйте, какие классы чаще путаются между собой, и оцените качество классификации для каждого класса.

Для задачи бинарной классификации постройте ROC Analysis, сравните площади под кривой (AUC) для разных моделей и выберите оптимальный порог классификации.

Используйте Test & Score с кросс-валидацией (CV=5 или CV=10) для сравнения производительности всех алгоритмов и проведения статистического анализа различий.

Результат:

- Сводная таблица метрик качества для всех моделей
- Матрицы ошибок и их интерпретация
- Выбор лучшей модели с обоснованием

Задание 5. Кластеризация данных

Подготовьте данные для кластеризации, удалите целевую переменную из признаков с помощью Select Columns. Если необходимо примените нормализацию с помощью Normalize.

Используйте k-Means с различным количеством кластеров (2-10), постройте график зависимости суммы квадратов внутрикластерных расстояний от k и примените "метод локтя" для выбора оптимального k. Примените k-Means с выбранным количеством кластеров, настройте количество инициализаций и максимальное число итераций. Получите кластерные метки для всех объектов.

Используйте Hierarchical Clustering, попробуйте различные метрики расстояния (Euclidean, Manhattan) и экспериментируйте с методами связи (single, complete, average).

Постройте дендрограмму.

Примените DBSCAN, настройте параметры eps (радиус окрестности) и min_samples. Проанализируйте количество выделенных кластеров и шума.

Результат:

- Результаты кластеризации различными алгоритмами
- Обоснование выбора количества кластеров

Задание 6. Оценка качества кластеризации

Вычислите коэффициент силуэта (Silhouette Score), рассчитайте внутрикластерную и межкластерную изменчивость, сравните качество разных алгоритмов кластеризации.

Используйте Data Table для анализа состава кластеров, вычислите средние значения признаков по кластерам и опишите характеристики каждого кластера.

Если у вас есть целевая переменная, то сравните кластеры с истинными классами, используйте Confusion Matrix для сравнения. Вычислите Adjusted Rand Index (ARI) или другие внешние метрики.

Результат:

- Оценка качества кластеризации
- Интерпретация полученных кластеров

Задание 7. Визуализация результатов

Создайте Scatter Plot с предсказанными классами и Linear Projection для многомерных данных с цветовым кодированием по предсказанным классам. Визуализируйте дерево решений с Tree Viewer.

Для кластеризации создайте Scatter Plot с цветовым кодированием по кластерам, Hierarchical Clustering с дендрограммой и Silhouette Plot для анализа качества кластеров.

Сравните истинные классы с предсказанными классами, истинные классы с полученными кластерами. Используйте t-SNE или MDS для низкоразмерной визуализации.

Для анализа признаков используйте Nomogram для логистической регрессии, Feature Importance для дерева решений или Random Forest, Linear Projection с отображением важности признаков.

Результат:

- Комплект визуализаций результатов классификации и кластеризации
- Интерпретация полученных результатов

Задание 9. Анализ и интерпретация результатов

Проанализируйте преимущества и недостатки каждого алгоритма классификации, различия в качестве предсказаний, в чем влияние размера данных и количества признаков.

Опишите выявленные группы объектов при кластеризации, объясните, что объединяет объекты в кластерах, сравните результаты разных алгоритмов кластеризации.

Сравните результаты кластеризации с известными классами. Обсудите, когда кластеризацию можно заменить на классификацию, объясните согласованность результатов.

Сформулируйте рекомендации по выбору алгоритмов, обсудите ограничения примененных методов.

Результат:

- Комплексный анализ результатов с выводами
- Практические рекомендации

Важные рекомендации:

✓ Для классификации всегда используйте отдельную тестовую выборку, применяйте кросс-валидацию для надежной оценки, анализируйте не только общую точность, но и качество по классам, учитывайте дисбаланс классов при интерпретации результатов.

✓ Для кластеризации экспериментируйте с нормализацией данных, используйте несколько критериев для выбора количества кластеров, сравнивайте результаты разных алгоритмов, всегда интерпретируйте полученные кластеры через исходные признаки.