

ЛАБОРАТОРНАЯ РАБОТА № 3*

Тема: Анализ текстовых данных.

Цель: освоить основные методы обработки и анализа текстовых данных с использованием Orange Data Mining.

Задания:

1. По согласованию с преподавателем подготовить набор данных для анализа (корпус текстовых документов).
2. Выполнить предобработку и очистку текстов.
3. Применить метод векторизации текста.
4. Реализовать тематическое моделирование (LDA).
5. Построить модели классификации текстов.
6. Провести сентимент-анализ данных.
7. Визуализировать результаты анализа текстов.
8. Сохранить результаты проделанной работы в различных форматах для подготовки аналитического отчета.
9. Подготовить аналитический отчет по результатам работы.

В отчет обязательно должно входить:

- описание исходного набора данных;
- перечисление основных выполненных шагов с описанием используемых компонент Orange (их параметры);
- интерпретацию полученных результатов;
- ключевые выводы по используемым методам и полученным результатам.

Отчет должен сопровождаться экспортированными визуализациями из Orange и скринами построенных схем обработки.

Методические рекомендации по выполнению практического задания

Задание 1. Подготовка данных для анализа

Исходные данные.

Для выполнения работы можно использовать один из встроенных текстовых датасетов Orange (*Text Mining add-on*).

Например, можно использовать следующие:

- 1 book-excerpts.tab - отрывки из книг разных жанров
- 2 election-tweets-2016.tab - твиты о выборах 2016 года
- 3 grimm-tales.tab - сказки братьев Гримм
- 4 movie-reviews.tab - рецензии на фильмы

Структура данных:

- Столбец с текстом (обычно называется 'text' или 'content')
- Столбец с категорией/жанром (например, 'category' или 'genre')
- Дополнительные метаданные (автор, дата и т.п.)

Для импорта текстовых данных загрузите данные через виджет **Corpus**. В разделе "*Browse documentation datasets*" выберите один из датасетов или любой другой встроенный текстовый датасет. Данные автоматически загрузятся в формате корпуса Orange.

Далее необходимо будет провести анализ структуры корпуса. Используйте Corpus Info или Data Info для получения статистики:

- Общее количество документов (записей)
- Среднее количество слов в тексте
- Распределение длины текстов
- Количество уникальных категорий/меток

Для просмотра содержимого примените Data Table или Corpus Viewer для просмотра текстов. Изучите 5-10 примеров из разных категорий. Проанализируйте качество и особенности данных.

Если есть метки классов, используйте Distributions для анализа их распределения и оцените сбалансированность классов

Результат:

- Workflow импорта данных
- Характеристика загруженного корпуса текстов

Задание 2. Предобработка текстовых данных

Необходимо провести **базовую очистку текста**, для этого используйте виджет **Preprocess Text** с настройками.

Transformation:

- Приведение к нижнему регистру (Lowercase)
- Удаление HTML-тегов (Strip HTML)
- Удаление акцентов (Strip accents)

Токенизация:

- Примените токенизацию по словам (Word tokenization)

- Настройте обработку пунктуации
- При необходимости используйте токенизацию по предложениям

Фильтрация

- Remove stopwords: удалите стоп-слова для вашего языка
- Filtering: Минимальная/максимальная длина слов; Удаление чисел (если не важны); Удаление слов с низкой частотой

Лемматизация/Стемминг

- Примените Stemming (для упрощения) или Lemmatization (если доступна)
- Сравните результаты до и после обработки

Создание N-грамм

- Экспериментируйте с биграммами и триграммами
- Настройте минимальную частоту для N-грамм

Результат:

- Workflow предобработки текста
- Сравнение словарей до и после обработки

Задание 3. Векторизация текста

Используйте **Bag of Words** для создания частотной матрицы. Настройте параметры: минимальная/максимальная частота слов и количество наиболее частых слов. Проанализируйте размерность полученной матрицы.

Примените Bag of Words с весами TF-IDF. Сравните с простым подсчетом частот и используйте Data Table для просмотра весов.

Далее проведите анализ словаря. Для этого подключите Word Cloud для визуализации частых слов. Используйте Most Frequent Words для анализа топ-слов. Выявите наиболее информативные термины

Примените LSA (Latent Semantic Analysis) для снижения размерности. Экспериментируйте с количеством компонент (50, 100, 200). Оцените качество аппроксимации.

Результат:

- Векторные представления текстов
- Анализ словаря и частотных характеристик

Задание 4. Тематическое моделирование

Проведите подготовку данных для LDA. Для этого используйте предобработанные тексты без излишней фильтрации. Убедитесь в достаточном размере словаря. При необходимости скорректируйте параметры фильтрации.

Далее для построения LDA модели примените Topic Modelling с алгоритмом LDA. Для малых корпусов (30-100 текстов) используйте максимум 8-10 топиков.

Настройте параметры:

- Количество итераций (по умолчанию)
- При возможности - другие параметры модели

Для анализа качества топиков используйте Topic Modelling для просмотра топиков. Для каждого топика проанализируйте топ-10 слов. Оцените, можно ли дать осмысленное название топика.

Постройте модели с разным количеством топиков (3, 5, 7). Выберите количество, дающее наиболее интерпретируемые результаты. Учитывайте размер вашего корпуса.

Дайте содержательные названия каждому топика. Проанализируйте ключевые слова топиков. Найдите примеры документов для каждого топика

Результат:

- LDA модель с оптимальным количеством топиков
- Интерпретация выделенных тематик
- Распределение документов по топикам

Задание 5. Классификация текстов

Для подготовки данных для классификации используйте Select Columns для определения текстовых признаков и целевой переменной. Разделите данные на обучающую и тестовую выборки с помощью Data Sampler. Убедитесь в сбалансированности классов.

Примените TF-IDF векторизацию к данным. При необходимости используйте снижение размерности.

Примените различные алгоритмы классификации:

- Naive Bayes
- Logistic Regression
- SVM с линейным ядром

Для оценки качества классификации используйте Test & Score с кросс-валидацией. Примените Predictions для получения предсказаний. Проанализируйте Confusion Matrix. Вычислите метрики качества (Accuracy, Precision, Recall, F1-score).

Проведите анализ ошибок классификации. Для этого найдите наиболее проблематичные документы. Проанализируйте причины неправильных классификаций.

Результат:

- Сравнение алгоритмов классификации текстов
- Анализ качества и ошибок классификации

Задание 6. Сентимент-анализ

Подготовьте данные для сентимент-анализа.

Для этого: если в данных есть оценки/рейтинги, преобразуйте их в классы тональности:

- Позитивный (высокие оценки)
- Негативный (низкие оценки)
- Нейтральный (средние оценки, опционально)

Используйте Feature Constructor для создания меток тональности

При наличии словаря тональности, примените его для анализа. Подсчитайте количество позитивных/негативных слов в текстах. Создайте признаки на основе тональных словарей.

Обучите классификаторы для определения тональности. Сравните качество разных алгоритмов. Используйте специфичные для тональности признаки (эмодзи, пунктуация).

Результат:

- Модель сентимент-анализа
- Анализ тональных характеристик корпуса

Задание 7. Визуализация результатов анализа текстов

Для визуализации словаря используйте:

- Word Cloud: облака слов для всего корпуса и по категориям
- Most Frequent Words: гистограммы частот слов

Для визуализации топики используйте:

- Scatter Plot: распределение документов по топикам (используйте веса топики как координаты)
- Heat Map: матрица топик-слово для анализа тематического содержания
- Bar Plot: распределение документов по доминирующим топикам

Для визуализации классификации:

- Confusion Matrix: для анализа ошибок классификации
- ROC Curves: для бинарной классификации
- Scatter Plot: визуализация документов в пространстве главных компонент с цветовым кодированием по классам

Результат:

- Комплексная визуализация результатов анализа текстов
- Интерпретация визуальных паттернов

Задание 9. Анализ и интерпретация результатов

Проанализируйте когерентность и интерпретируемость топики. Оцените покрытие тематического пространства. Сравните с ожидаемой тематической структурой

Сравните производительность различных алгоритмов. Обоснуйте влияние размера словаря и метода векторизации. Проанализируйте сложность классификации для разных классов.

Сопоставьте результаты тематического моделирования и классификации. Оцените согласованность разных методов анализа.

Результат:

- Комплексный анализ результатов с выводами
- Практические рекомендации по анализу текстовых данных