

---

## *ПРАКТИЧЕСКАЯ РАБОТА*

---

### **Приемы подготовки и обработки данных для машинного обучения**

В настоящее время в открытом доступе находится значительное количество данных, которые могут быть использованы для машинного обучения (наборы данных = «датасеты»). Это связано, в частности, с тем, что ведущие научные журналы при публикации статей требуют и обнародования соответствующих датасетов. Ещё одна важная цель – дать возможность апробации новых алгоритмов в сфере машинного обучения на одинаковых данных, для сравнения достигаемой точности моделей.

Однако, формат данных в общедоступных датасетах редко в точности соответствует тому, который требуется в конкретном проекте. Таким образом, первым этапом (после, конечно, нахождения подходящего датасета) является подготовка данных. Это может включать в себя:

1. очистку данных: например, удаление некорректных значений, таких как отрицательный или нереально большой возраст клиента,
2. обработку пропущенных значений: например, их удаление.
3. преобразование данных, представленных в шкале категорий (в большинстве случаев нейросетевые модели работают с числовыми данными).
4. разделение имеющихся данных на обучающую и тестовую выборку: например, в пропорции 0,8:0,2.
5. нормализацию данных: например, вычитанием мат. ожидания и делением на среднее отклонение

Часто на этапе подготовки данных производится также их первичное изучение. Например, средства классической описательной статистики позволяют вычислить математическое ожидание, дисперсию и прочие характеристики.

Удобным способом первичного изучения данных является также их графическое представление в диаграммах соответствующего формат

### Задание 1.

- 1) Сгенерировать выборку из 1000 значений, распределенных по нормальному закону с параметрами  $\mu = 8, \sigma = 10$ .
- 2) Сделать выборку из 500 значений.

3) Для выборок из п.1 и п.2:

Выполнить очистку данных – отрицательные значения заменить на положительные.

Рассчитать числовые характеристики. Построить гистограммы.

Стандартизировать данные.

Вычислить числовые характеристики. Построить гистограмму.

Нормализовать данные в диапазоне  $[0;1]$ .

Чтобы получить значения в наборе данных от 0 до 1 используем формулу:

$$Z_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

### Задание 2

Предположим  $X$  и  $Y$  две случайные переменные отражающие возраст и вес, соответственно.

Рассмотрим случайную выборку из 20 наблюдений

$X = (69, 74, 68, 70, 72, 67, 66, 70, 76, 68, 72, 79, 74, 67, 66, 71, 74, 75, 75, 76)$

$Y = (153, 175, 155, 135, 172, 150, 115, 137, 200, 130, 140, 265, 185, 112, 140, 150, 165, 185, 210, 220).$

Необходимо:

1. Найти среднее, медиану и моду величины  $X$ .
2. Найти дисперсию  $Y$ .
3. Построить график нормального распределения для  $X$ . Функция =НОРМ.РАСП().
4. Построить гистограммы признаков.
5. Найти вероятность того, что возраст больше 60.
6. Определить корреляцию между  $X$  и  $Y$ .
7. Построить диаграмму рассеяния, отображающую зависимость между возрастом и весом.
8. Рассчитать коэффициенты линейного уравнения регрессии.
9. Выполнить классификацию признаков на основе полученного уравнения.

## Методические указания.

1). Сгенерировать выборку 1000 значений, распределенных по нормальному закону с параметрами  $\mu = 8$ ,  $\sigma = 10$ .

Используем Анализ данных – Генерация случайных чисел:

Генерация случайных чисел

Число переменных: 1

Число случайных чисел: 1000

Распределение: Нормальное

Параметры

Среднее = 8

Стандартное отклонение = 10

Случайное рассеивание:

Параметры вывода

☒ Выходной интервал: \$A\$2

☐ Новый рабочий лист:

☐ Новая рабочая книга

OK Отмена Справка

*Результат:*

|    | A                 | B | C |
|----|-------------------|---|---|
| 1  | <b>1000 чисел</b> |   |   |
| 2  | -7,99069          |   |   |
| 3  | 9,65569           |   |   |
| 4  | 7,816009          |   |   |
| 5  | 10,75434          |   |   |
| 6  | 1,144479          |   |   |
| 7  | 18,36178          |   |   |
| 8  | 9,63941           |   |   |
| 9  | -4,2513           |   |   |
| 10 | -4,73197          |   |   |
| 11 | 11,80215          |   |   |

*Выборка 500 чисел:*

Выборка

Входные данные

Входной интервал: \$A\$2:\$A\$1001

☐ Метки

Метод выборки

☐ Периодический

Период:

☒ Случайный

Число выборок: 500

Параметры вывода

☒ Выходной интервал: \$C\$2

☐ Новый рабочий лист:

☐ Новая рабочая книга

OK Отмена Справка

Результат:

|    | A          | B | C         |
|----|------------|---|-----------|
| 1  | 1000 чисел |   | 500 чисел |
| 2  | -7,99069   |   | 1,552035  |
| 3  | 9,65569    |   | 11,02714  |
| 4  | 7,816009   |   | 4,556085  |
| 5  | 10,75434   |   | 8,988825  |
| 6  | 1,144479   |   | 4,811493  |
| 7  | 18,36178   |   | 21,15991  |
| 8  | 9,63941    |   | -3,49294  |
| 9  | -4,2513    |   | 10,15587  |
| 10 | -4,73197   |   | 21,61341  |
| 11 | 11,89316   |   | 13,0424   |

Очистка данных:

|    | A          | B | C         | D | E                | F | G |
|----|------------|---|-----------|---|------------------|---|---|
| 1  | 1000 чисел |   | 500 чисел |   | Исправленные 500 |   |   |
| 2  | -7,99069   |   | 1,552035  |   | 1,552035         |   |   |
| 3  | 9,65569    |   | 11,02714  |   | 11,02714         |   |   |
| 4  | 7,816009   |   | 4,556085  |   | 4,556085         |   |   |
| 5  | 10,75434   |   | 8,988825  |   | 8,988825         |   |   |
| 6  | 1,144479   |   | 4,811493  |   | 4,811493         |   |   |
| 7  | 18,36178   |   | 21,15991  |   | 21,15991         |   |   |
| 8  | 9,63941    |   | -3,49294  |   | 3,492943         |   |   |
| 9  | -4,2513    |   | 10,15587  |   | 10,15587         |   |   |
| 10 | -4,73197   |   | 21,61341  |   | 21,61341         |   |   |
| 11 | 11,89316   |   | 13,0424   |   | 13,0424          |   |   |
| 12 | 12,81008   |   | 27,01844  |   | 27,01844         |   |   |

Рассчитать числовые характеристики.

Анализ данных – Описательная статистика:

Описательная статистика

Входные данные

Входной интервал:

\$A\$2:\$A\$1001

↑

Группирование:

☒ по столбцам
 ☐ по строкам

☐ Метки в первой строке

Параметры вывода

☒ Выходной интервал:
 

\$H\$1

↑

☐ Новый рабочий лист:

☐ Новая рабочая книга

☒ Итоговая статистика

☒ Уровень надежности:
 

95

%

☒ К-ый наименьший:
 

1

☒ К-ый наибольший:
 

1

OK

Отмена

Справка

Результат:  
Для 1000 значений

| Н                      | I            | J | K                      | L        |
|------------------------|--------------|---|------------------------|----------|
| 1000 значений          |              |   | 500 значений           |          |
| Среднее                | 7,809780275  |   | Среднее                | 10,46258 |
| Стандартная ошибка     | 0,330493382  |   | Стандартная ошибка     | 0,32448  |
| Медиана                | 8,05316565   |   | Медиана                | 9,118832 |
| Мода                   | 9,016496753  |   | Мода                   | 4,597229 |
| Стандартное отклонение | 10,4511184   |   | Стандартное отклонение | 7,255601 |
| Дисперсия выборки      | 109,2258757  |   | Дисперсия выборки      | 52,64375 |
| Эксцесс                | -0,07450365  |   | Эксцесс                | 0,606223 |
| Асимметричность        | -0,02567419  |   | Асимметричность        | 0,868801 |
| Интервал               | 69,23801266  |   | Интервал               | 37,55426 |
| Минимум                | -26,01073627 |   | Минимум                | 0,070525 |
| Максимум               | 43,22727638  |   | Максимум               | 37,62479 |
| Сумма                  | 7809,780275  |   | Сумма                  | 5231,288 |
| Счет                   | 1000         |   | Счет                   | 500      |
| Наибольший(1)          | 43,22727638  |   | Наибольший(1)          | 37,62479 |
| Наименьший(1)          | -26,01073627 |   | Наименьший(1)          | 0,070525 |
| Уровень надежности     | 0,648540867  |   | Уровень надежности(9   | 0,637516 |

Построить гистограммы.

Гистограмма

Входные данные

Входной интервал: 

↑

Интервал карманов: 

↑

☐ Метки

Параметры вывода

☒ Выходной интервал: 

↑

☐ Новый рабочий лист:

☐ Новая рабочая книга

☐ Парето (отсортированная гистограмма)


☐ Интегральный процент

☒ Вывод графика


OK

Отмена

Справка



Для 500:



Стандартизируем данные (500 наблюдений): вычитанием мат. ожидания и делением на стандартное отклонение:

Аргументы функции

НОРМАЛИЗАЦИЯ

|                  |    |   |              |
|------------------|----|---|--------------|
| X                | E2 | = | 1,552034994  |
| Среднее          | N3 | = | 10,46257531  |
| Стандартное откл | N7 | = | 7,255601157  |
|                  |    | = | -1,228091253 |

Возвращает нормализованное значение.

**Стандартное откл** стандартное отклонение распределения, положительное число.

Значение: -1,228091253


[Справка по этой функции](#)

OK Отмена

Рассчитаем числовые характеристики:

| Стандатизированные 500 |          |
|------------------------|----------|
| Среднее                | -9,8E-17 |
| Стандартная ошибка     | 0,044721 |
| Медиана                | -0,1852  |
| Мода                   | -0,80839 |
| Стандартное отклонен   | 1        |
| Дисперсия выборки      | 1        |
| Экссесс                | 0,606223 |
| Асимметричность        | 0,868801 |
| Интервал               | 5,1759   |
| Минимум                | -1,43228 |
| Максимум               | 3,74362  |
| Сумма                  | -4,9E-14 |
| Счет                   | 500      |
| Наибольший(1)          | 3,74362  |
| Наименьший(1)          | -1,43228 |
| Уровень надежности(9   | 0,087865 |

Гистограмма:



Нормализуем данные:

| J                   | K |
|---------------------|---|
| Нормализованные 500 |   |
| 0,03945             |   |
| 0,291754            |   |
| 0,119442            |   |
| 0,237478            |   |
| 0,126243            |   |
| 0,561571            |   |
| 0,091133            |   |
| 0,268554            |   |
| 0,573647            |   |
| 0,345447            |   |